

ROCm 双 GPU 工具包 — 通俗版说明

给非技术读者： 本页用通俗语言解释工具包的作用，不涉及技术配置步骤。完整技术指南请见 [README.zh-CN.md](#)。

Copyright 2026 cubecloud Limited (<https://cubecloud.io>) · 基于 [Apache License 2.0](#) 许可

这个工具包是什么？

这是一个帮助你在**一台 Windows 电脑上同时启用两块 AMD 图形处理器（GPU）**的工具包，让它们都能运行 AMD 的 ROCm 软件平台——ROCm 是让 GPU 加速人工智能和机器学习任务的软件层。

为什么需要两块 GPU？

很多现代 AMD 电脑内置了**两块 GPU**：

GPU	是什么	内存
iGPU（集成显卡）	内置在处理器芯片中	共享系统内存（Strix Halo 上最高 88 GB）
dGPU（独立显卡）	单独的显卡	有自己的专用内存（如 RX 7900 XTX 的 24 GB）

问题在于：AMD 的 ROCm 软件在 Windows 上不会自动配置两块 GPU 同时工作。每块 GPU 需要不同的软件设置，而且它们之间不能直接共享内存。

工具包做了什么？

工具包解决了三个问题：

1. 让两块 GPU 都能运行 ROCm

- **iGPU** 配置了轻量级的 Python 版 ROCm（TheRock 轮子包）
- **dGPU** 配置了 AMD 官方的 HIP SDK（系统级安装包）
- 两块 GPU 都能独立运行 ROCm 程序

2. 证明它们可以共享数据（有变通方案）

AMD 把大多数 iGPU+dGPU 组合标记为“非对等” (non-peers) —— 意思是它们不能直接在彼此的内存之间拷贝数据。工具包包含一个测试程序，证明了：

- ❌ GPU 之间直接拷贝内存：不可行（驱动限制）
- ✅ 通过系统内存中转拷贝：可行 —— 软件自动通过系统内存作为桥梁传输数据
- ✅ 数据能正确到达另一块 GPU

3. 实现双 GPU 加速 AI 模型（通过 Ollama）

对于通过 Ollama 运行本地 AI 模型（如 Gemma、Qwen 等）：


- 同时运行两个模型：**在 iGPU（88 GB —— 几乎能容纳任何模型）上加载一个大模型，在 dGPU（24 GB）上加载一个小模型。两者同时运行，为不同用户或任务并行服务。
- 单个模型：**完全在 iGPU 上运行，其内存足以容纳大多数高达约 700 亿参数的模型。

验证了什么？

所有发现均在真实硬件上测试验证：

组件	详情
处理器	AMD Ryzen AI MAX+ 395 (Strix Halo)
iGPU	AMD Radeon 8060S Graphics (gfx1151) — 88 GB 共享内存
dGPU	AMD Radeon RX 7900 XTX (gfx1100) — 24 GB 专用内存
软件	AMD HIP SDK 7.1.0、TheRock 7.13.0、Ollama 0.30.11
驱动	AMD Adrenalin 32.0.31019.2002

性能：预期效果



核心结论：iGPU 的 88 GB 共享内存是这台机器最大的优势。它几乎可以把任何 AI 模型完整放入高速 GPU 内存中。dGPU 则提供了第二条通道，可以同时运行另一个不同的模型。

什么做不到？

功能	原因
将一个模型拆分到两块 GPU 上	两块 GPU 不能直接共享内存（非对等）；强制拆分会慢 10-50 倍

关于 NPU 的说明

本方案不仅依赖 Ollama，还支持 **LM Studio** 和 **Lemonade Server**，这些平台都支持 NPU（XDNA 加速器）。NPU 可以在 AI 推理中分担部分工作负载，与 GPU 形成互补。

为什么添加 dGPU？

添加 dGPU 的目的不是减少 iGPU 的内存，而是**为 iGPU 分担重负载**。当 iGPU 在处理大型模型时，dGPU 可以同时运行另一个模型或处理其他推理任务，从而**整体加速模型推理能力**。两块 GPU 各司其职，协同工作，实现更高的总吞吐量。

适合谁用？

- **企业**：在 AMD 硬件上运行本地 AI 模型，不依赖云端
- **开发者**：需要在 Windows 上让两块 GPU 都运行 ROCm
- **OEM 厂商**：构建 AMD 双 GPU 系统并希望有可复现的配置方案

许可

Copyright 2026 cubecloud Limited。基于 Apache License 2.0 许可 —— 可免费用于商业和个人用途。

详见 [LICENSE](#)。